

FIAP

LARISSA ARAÚJO GAMA ALVARENGA – 96496 - 2TDSPS

LARISSA LOPES OLIVEIRA – 552628 - 2TDSPB

LUNA FAUSTINO LIMA – 552473 - 2TDSPB

GLOBAL SOLUTION - DISRUPTIVE ARCHITECTURES

São Paulo

2024

LINK VÍDEO

https://youtu.be/L_EuOEd2BiE

REPOSITÓRIO GITHUB

<https://github.com/LunaFaustino/GS-2024-IA.git>

DESCRIÇÃO DO PROBLEMA E SOLUÇÃO

A identificação de falhas ou condições das placas solares é crucial para a manutenção de sistemas de energia solar. Um erro na detecção pode resultar em quedas de eficiência ou danos irreversíveis aos equipamentos. Para abordar esse problema, o objetivo deste trabalho foi utilizar técnicas de aprendizado profundo para classificar imagens de placas solares em diferentes categorias:

- **Clean:** Placa limpa, sem sujeiras ou obstruções.
- **Dusty:** Placa coberta de poeira, o que pode reduzir a eficiência da geração de energia.
- **Electrical-damage:** Placa com danos elétricos visíveis, como circuitos ou conexões danificadas.
- **Physical-damage:** Placa com danos físicos, como rachaduras ou quebras.
- **Snow-Covered:** Placa coberta por neve, o que pode interferir na sua performance.

Utilizamos o banco de dados [Solar Panel Images Clean and Faulty Images](#) disponível no Kaggle, que contém imagens dessas diferentes condições de placas solares.

METODOLOGIA

A abordagem adotada para a resolução do problema:

- **Pré-processamento de Dados:**
 - As imagens foram redimensionadas para o tamanho de 244x244 pixels.
 - A divisão do conjunto de dados foi realizada em 80% para treinamento e 20% para validação.
- **Modelo Baseado em Transfer Learning:**
 - Utilizamos o **VGG16**, um modelo pré-treinado com o conjunto de dados ImageNet.
 - Inicialmente, as camadas do modelo base foram congeladas para otimizar o treinamento, usando o processo de *fine-tuning* para melhorar o desempenho do modelo.
- **Treinamento:**
 - A função de perda escolhida foi a **SparseCategoricalCrossentropy**, apropriada para problemas de classificação com múltiplas classes.
 - O otimizador **Adam** foi utilizado, com taxa de aprendizado inicial de 0.001, ajustada posteriormente para 0.0001 durante o fine-tuning.
- **Avaliação do Modelo:**
 - Durante o treinamento, a acurácia do modelo foi monitorada, com o uso de callbacks de **EarlyStopping** para evitar overfitting.
 - O modelo foi avaliado no conjunto de validação e os resultados foram analisados.

RESULTADOS OBTIDOS

- **Treinamento Inicial:**

- O modelo inicial, utilizando VGG16 com camadas congeladas, alcançou uma acurácia de **76%** no conjunto de validação.

- **Fine-Tuning:**

- Após desbloquear as camadas superiores do modelo VGG16 e realizar o fine-tuning, a acurácia foi significativamente melhorada, atingindo **99%** no conjunto de validação.

- **Avaliação Final:**

- Durante a avaliação final, o modelo obteve uma acurácia de **86%** no conjunto de validação, cometendo apenas 2 erros. As imagens que foram erradas são realmente mais difíceis de identificar, uma sendo “Bird Drop”, mas parece ser poeira, a outra sendo “Dusty”, mas o reflexo da luz na placa faz parecer que ela está limpa.

REFERÊNCIA

[Solar Panel Images Clean and Faulty Images](#)